

Natural Language Processing

Laboratorio #1

Preparación de un corpus y EDA

Instrucciones generales

- Individual
- Entrega: **Domingo 2 de agosto, 2026. 23:59.**
- Trabajar en Python, en un Jupyter Notebook o script (.py).
- Instalar las librerías necesarias: pandas, nltk, matplotlib. Muchas de los requerimientos de NLP ya se encuentra implementados en el modulo NLTK. Investigue.

1. Descargar el corpus

"Spanish News Classification": un conjunto de noticias reales en español organizadas por categoría (deportes, economía, política, etc.).

Enlace de descarga: <https://www.kaggle.com/datasets/kevinmorgado/spanish-news-classification>

2. Explorar el corpus antes de tocarlo

Cargue el archivo y responda las siguientes preguntas dentro del notebook (en celdas de texto):

- ¿Cuántos documentos tiene el corpus?
- ¿Qué columnas contiene y qué información guarda cada una?
- ¿Cuántas categorías hay y cómo se distribuyen?
- ¿Hay filas vacías o duplicadas?

3. Preparación del corpus

Aplique sobre el corpus real el mismo pipeline de normalización visto en clase en este orden y, después de cada paso, cuente cuántos tokens y cuántos tipos (palabras distintas) quedan:

- i. Tokenización — divide cada documento en tokens.
- ii. Minúsculas — convierte todo el texto a minúsculas.
- iii. Eliminar puntuación — quita comas, puntos, signos & i, etc.
- iv. Eliminar stopwords — quita palabras muy frecuentes y poco informativas.
- v. Lematizar — reduce cada palabra a su forma de diccionario.

4. ¿Qué es un EDA?

Investigue y conteste las siguientes preguntas:

- ¿Qué es un Análisis Exploratorio de Datos (EDA)?
- ¿Qué busca lograr un EDA dentro de un proyecto de ciencia de datos?

5. EDA sobre tu corpus

Con el corpus ya preparado, calcule y presente lo siguiente:

- Tokens y tipos: total de tokens y tamaño del vocabulario (tipos), antes y después de normalizar. Calcula en qué porcentaje se redujo el vocabulario.
- Riqueza léxica: razón tipo/token (types/tokens), global y por categoría de noticia.
- Tabla de frecuencias: las 20 palabras más frecuentes del corpus normalizado, con su frecuencia.
- Histograma: distribución de la cantidad de tokens por documento.
- Ley de Zipf: gráfico de frecuencia vs. rango en escala log-log. Compara la forma de tu curva con la curva teórica $f(\text{rango}) \approx k / \text{rango}$ vista en clase.
- Comparación por categoría: las 10 palabras más frecuentes de al menos dos categorías distintas, comentando las diferencias.
- Nube de palabras del vocabulario normalizado.

6. Análisis

- ¿La curva de Zipf del corpus se parece a la curva teórica vista en clase? ¿Qué diferencias observa y por qué cree que ocurren?
- ¿Cuánto se redujo el vocabulario en cada paso de normalización? ¿Cuál tuvo mayor impacto?
- ¿Encontró algún caso donde quitar stopwords haya afectado el significado de una noticia?
- ¿Qué desafíos propios del español encontró realmente en el corpus?
- Si tuviera que entrenar un modelo de lenguaje con este corpus, ¿normalizaría de la misma forma? Justifique.

Entregables

Entregable	Contenido
Notebook o script	Código completo y comentado: carga, preparación del corpus y EDA.
Reporte escrito (máx. 4 páginas)	Investigación sobre EDA, EDA y análisis de resultados