

Laboratorio #1 — Análisis Exploratorio del corpus Spanish News Classification

Natural Language Processing · Universidad Francisco Marroquín
Milton Beltrán · Agosto 2026

Este reporte presenta el **Análisis Exploratorio de Datos (EDA)** del corpus *Spanish News Classification* (1217 noticias en español, 7 categorías temáticas), junto con los **hallazgos** más relevantes y la **justificación de las decisiones** de preparación. El código completo (carga, exploración, pipeline de normalización y las preguntas de investigación y análisis) se encuentra en el notebook `lab1.ipynb` del repositorio enlazado al final. Como paso previo se eliminaron **75 filas exactamente duplicadas** (el corpus de trabajo queda en **1142 documentos**), ya que inflaban artificialmente las frecuencias y la distribución por categoría.

EDA del corpus

1. Reducción del vocabulario: tokens y tipos, antes vs. después

Se aplicó el pipeline de normalización (tokenización → minúsculas → eliminación de puntuación → eliminación de *stopwords* → *stemming*), contando después de cada paso el total de **tokens** (ocurrencias) y de **tipos** (palabras distintas):

Paso	Tokens	Tipos	Δ Tipos
i. Tokenización	632,745	38,947	—
ii. Minúsculas	632,745	36,099	-7.3 %
iii. Quitar puntuación	579,676	27,315	-24.3 %
iv. Quitar <i>stopwords</i>	299,799	27,104	-0.8 %
v. <i>Stemming</i>	299,799	13,103	-51.6 %

El vocabulario se redujo de **38,947 a 13,103 tipos (-66.4 %)** entre la tokenización y el final del pipeline. El análisis por paso revela un contraste importante:

- La **eliminación de *stopwords*** es el paso que **más reduce los tokens** (-48.3 %), porque las palabras funcionales (`de` , `la` , `que` , `el`) son las más repetidas del corpus; en cambio, casi no afecta el vocabulario (-0.8 %).
- El ***stemming*** es el paso que **más reduce los tipos** (-51.6 %), al colapsar familias de palabras en una raíz común (`sostenible` / `sostenibilidad` → `sosten...`), sin alterar el número de ocurrencias.

Decisiones y su justificación. (i) La puntuación se eliminó con `token.isalpha()`, lo que descarta signos — incluidos los de apertura `¿` `i` — y conserva tildes y `ñ`; como costo, también descarta números, aceptable para un vocabulario más limpio. (ii) Como NLTK no ofrece lematización para español, se usó `SnowballStemmer`, que es **stemming** (recorte de sufijos) y **no lematización** real: produce raíces que no son palabras de diccionario (`banc` , `pod`). Para el EDA visual se conservaron **dos versiones** del corpus: una legible sin *stemming* (para la nube y el top-20) y otra con *stemming* (para los conteos y la Ley de Zipf).

2. Riqueza léxica (razón tipo/token)


La razón **tipo/token (TTR)** mide la diversidad léxica: cuántas palabras distintas hay por cada ocurrencia. Sobre el corpus normalizado legible (sin *stemming*) la TTR global es **0.090** (27,104 tipos / 299,799 tokens); con *stemming* baja a **0.044**, coherente con el colapso de familias de palabras. Por categoría (corpus legible):

Categoría	Documentos	Tokens	Tipos	TTR
Reputacion	26	7,197	2,976	0.414
Regulaciones	142	35,109	8,815	0.251
Alianzas	247	46,122	10,523	0.228
Otra	130	25,803	5,576	0.216

Categoría	Documentos	Tokens	Tipos	TTR
Sostenibilidad	125	51,341	10,333	0.201
Innovación	152	49,185	8,931	0.182
Macroeconomía	320	85,042	11,320	0.133


Se observa una relación **inversa entre el tamaño de la categoría y su TTR**: Reputación (la más pequeña, 26 docs) tiene la mayor diversidad (0.414), mientras que Macroeconomía (la más grande, 320 docs) la menor (0.133). Es el comportamiento esperado, ya que a mayor volumen de texto las palabras se repiten más y la proporción de tipos nuevos disminuye (por eso la TTR no debe compararse entre corpus de tamaños muy distintos sin normalizar).

3. Palabras más frecuentes (top-20)



Domina de forma notable **bbva** (2,160 ocurrencias), seguida de vocabulario económico (inflación, banco, millones, precios, crecimiento, mercado). Esto revela un **sesgo de fuente**: el corpus proviene en gran medida de noticias financieras ligadas a BBVA, lo cual condiciona todo el análisis léxico.


4. Distribución de tokens por documento



La longitud de los documentos (corpus normalizado) va de **0 a 1,479 tokens**, con **media 262.5** y **mediana 226**. La distribución está **sesgada a la derecha** (cola larga de noticias muy extensas). El mínimo de **0 tokens** es un

hallazgo relevante: algún documento quedó vacío tras la normalización (compuesto solo por *stopwords*, puntuación o números).

5. Ley de Zipf



La curva del corpus (azul) sigue la tendencia decreciente característica de la **Ley de Zipf**, aproximándose a la recta teórica $f(rango) \approx k/rango$ (roja). El ajuste es bueno en el rango medio, pero se desvía en los **extremos**: en los rangos altos las palabras más frecuentes aparecen algo por debajo de lo que predice la curva ideal, y en la **cola** hay un escalón por las miles de palabras que aparecen una sola vez (*hapax legomena*).

6. Comparación por categoría

Top-10 de palabras (corpus legible) en tres categorías:

#	Macroeconomía	Sostenibilidad	Innovación
1	inflación	bbva	bbva
2	precios	energía	clientes
3	año	sostenible	datos
4	bbva	agua	banco
5	crecimiento	sostenibilidad	empresas
6	mayor	además	digital
7	alimentos	millones	través
8	aumento	puede	innovación
9	tasa	cambio	tecnología
10	economía	cada	españa

Las diferencias son claras y coherentes con cada temática: **Macroeconomía** gira en torno a indicadores (inflación, precios, tasa, crecimiento); **Sostenibilidad** al medio ambiente (energía, agua, sostenible, cambio); e **Innovación** a lo digital (datos, digital, tecnología, innovación). La palabra *bbva* aparece en todas, confirmando el sesgo de fuente transversal al corpus.

7. Nube de palabras



La nube (vocabulario normalizado legible) resume visualmente lo anterior: **bbva** y el léxico económico-financiero concentran la mayor presencia.

Hallazgos y retos del español

- **Sesgo de fuente:** bbva es la palabra más frecuente por amplio margen; el corpus está dominado por noticias financieras ligadas a esa entidad.
- **Diversidad léxica y tamaño:** la TTR es inversamente proporcional al tamaño de la categoría, por lo que no es comparable directamente entre categorías de distinto volumen.
- **Duplicados desiguales:** los 75 duplicados eliminados no estaban repartidos de forma uniforme (p. ej., *Innovación* pasó de 195 a 152 documentos), lo que habría distorsionado la comparación entre categorías de no haberse limpiado.
- **Documentos vacíos:** al menos un documento quedó con 0 tokens tras la normalización, señal de que un preprocesamiento agresivo puede vaciar textos cortos.
- **Retos propios del español:**
 - El *stemming* con Snowball **elimina las tildes** (andrés → andres , aseguró → asegur) y genera **raíces que no son palabras reales** (banc , pod), a diferencia de una lematización verdadera.
 - La lista de *stopwords* de NLTK incluye la **negación no** ; eliminarla puede **invertir el significado** de una noticia (p. ej., "el banco **no** aprobó el crédito" pierde la negación), un riesgo relevante para tareas de sentimiento.
 - Los signos de apertura { , ¡ , ¡ y los clíticos son particularidades que obligan a tokenizar y normalizar con criterio específico para el idioma.

Repositorio

Código, notebook y este reporte: <https://github.com/MrCifristo/lab1-nlp>