

Natural Language Processing
Laboratorio #4
Modelos Lineales

Instrucciones generales

- Individual.
- Entrega: Lunes 24 de agosto, 2026. 23:59.
- Trabajar en Python, en un Jupyter Notebook o script (.py).

Antes de iniciar, asegúrese de tener disponibles en su notebook, desde los laboratorios anteriores:

- El DataFrame del corpus con el texto original, el texto normalizado y la columna de categoría.
- El pipeline de normalización completo.
- Las representaciones vectoriales del corpus (Bolsa de Palabras y TF-IDF).
- Los conjuntos de entrenamiento, validación y prueba (70/15/15, estratificados) construidos en el Laboratorio #3.
- El clasificador Naive Bayes entrenado y evaluado en el Laboratorio #3, junto con sus métricas y matrices de confusión (BoW y TF-IDF).

1. Construcción del clasificador de regresión logística

Entrene un clasificador de regresión logística (**LogisticRegression** de scikit-learn) para el mismo problema de clasificación de categorías del Laboratorio #3.

- Entrene un primer modelo usando como features la matriz de Bolsa de Palabras (CountVectorizer) ajustada únicamente con el conjunto de entrenamiento.
- Entrene un segundo modelo usando como features la matriz TF-IDF (TfidfVectorizer), ajustada de la misma forma.
- **Importante:** reutilice exactamente las mismas particiones (entrenamiento/validación/prueba) y los mismos vectorizadores ajustados (fit) en el Laboratorio #3, para que la comparación entre modelos sea justa.
- Haga los ajustes necesarios tomando en cuenta que el dataset tiene más de dos categorías.
- Explique con sus propias palabras qué representan $z = w \cdot x + b$ y la función sigmoide $\sigma(z) = 1/(1+e^{-z})$ en este contexto, y cómo se convierte ese puntaje en una probabilidad y luego en una predicción de clase.

2. Entrenamiento y evaluación

Evalúe ambos modelos (BoW y TF-IDF) sobre el conjunto de validación y, al final, sobre el conjunto de prueba.

- Reporte accuracy, precision, recall y F1-score (macro y ponderado) para cada modelo, usando `classification_report` de scikit-learn.
- Construya y grafique la matriz de confusión de cada modelo con las categorías del corpus en los ejes.
- Compare el desempeño en entrenamiento contra el desempeño en validación/prueba. ¿Hay indicios de overfitting? Relacione su respuesta con lo visto en clase sobre generalización.
- Indique cuál de las dos representaciones (BoW o TF-IDF) obtuvo mejor desempeño con regresión logística y proponga una explicación.

3. Interpretación de pesos

Una de las principales diferencias frente a Naive Bayes es que la regresión logística aprende un peso por característica de forma conjunta, optimizando directamente la separación entre clases.

- Para el mejor modelo de la sección anterior, extraiga los coeficientes (`coef_`) y liste las 15 palabras con mayor peso positivo y las 15 con mayor peso negativo para dos o tres categorías del corpus.
- ¿Tienen sentido esas palabras como evidencia a favor o en contra de cada categoría?
- Compare estas palabras con las de mayor $P(w_i|c)$ (verosimilitud) obtenidas con Naive Bayes en el Laboratorio #3 para las mismas categorías. ¿Coinciden en su mayoría? ¿Qué diferencias encuentra y a qué las atribuye?

4. Comparación con Naive Bayes

Retome los resultados del Laboratorio #3 (Naive Bayes con BoW y TF-IDF) y compárelos con los modelos de regresión logística entrenados en este laboratorio.

- Construya una tabla comparativa con las cuatro combinaciones (Naive Bayes / Regresión logística × BoW / TF-IDF): representación, accuracy, F1 macro, F1 ponderado y tiempo de entrenamiento aproximado.
- ¿Qué modelo obtuvo mejor desempeño en general sobre el conjunto de prueba? ¿La diferencia es grande o marginal?
- Relacione la diferencia (o similitud) de desempeño con la forma en que cada modelo calcula sus pesos: estimación aislada de $P(w_i|c)$ bajo independencia condicional en Naive Bayes, frente a optimización conjunta de todos los pesos en regresión logística.

5. Análisis de errores

Con base en la matriz de confusión:

- Identifique las dos categorías que el modelo confunde con mayor frecuencia entre sí. Revise 3 a 5 documentos mal clasificados y comente qué características (palabras) pudieron llevar al modelo a equivocarse, apoyándose en los pesos del modelo.
- Compare estos errores con los que cometía Naive Bayes en el Laboratorio #3 sobre las mismas categorías: ¿son los mismos documentos, documentos distintos, o el mismo tipo de confusión?
- Relacione al menos un error encontrado con el supuesto de independencia condicional de Naive Bayes frente a la capacidad de la regresión logística de ponderar conjuntamente características correlacionadas.

6. Análisis

1. Naive Bayes y regresión logística son ambos clasificadores lineales para texto. ¿En qué se parecen y en qué difieren fundamentalmente en la forma en que llegan a sus pesos? Apóyese en sus resultados de las secciones 3 y 4.
2. La regresión logística aprende todos sus pesos a la vez, mientras que en Naive Bayes cada $P(w_i|c)$ se estima de forma aislada. ¿Encontró evidencia de esta diferencia en el análisis de pesos (sección 3) o de errores (sección 6)? Dé un ejemplo concreto.
3. ¿En qué situaciones (tamaño del corpus, tiempo de entrenamiento disponible, necesidad de probabilidades bien calibradas, interpretabilidad) preferiría Naive Bayes sobre regresión logística, y en cuáles sería al revés?
4. Calcule la línea base de clase mayoritaria (predecir siempre la categoría más frecuente) sobre el conjunto de prueba. ¿Qué tanto aportan sus modelos de Naive Bayes y regresión logística sobre esa línea base?
5. Si tuviera que poner en producción el modelo con mejor desempeño, ¿qué factores más allá del accuracy consideraría (tiempo de inferencia, interpretabilidad de los pesos, tamaño del modelo, facilidad de reentrenar con datos nuevos)? ¿Cambiaría su elección entre Naive Bayes y regresión logística?

Entregables

Entregable	Contenido
Link a repositorio	Repositorio (por ejemplo GitHub) con el código versionado del laboratorio.
Reporte escrito (máx. 4 páginas)	Resultados de las secciones 1 a 6 (modelos de regresión logística, métricas, matrices de confusión, interpretación de pesos, comparación con Naive Bayes y efecto de la regularización, análisis de errores) y respuestas al análisis (sección 7).