

Laboratorio #5

Modelos de lenguaje

Instrucciones generales

- Individual.
- Entrega: Lunes 7 de septiembre, 2026. 23:59.
- Trabajar en un Jupyter Notebook.

Dataset

“El ingenioso hidalgo Don Quijote de la Mancha”, de Miguel de Cervantes

Disponible en: <https://www.kaggle.com/datasets/manuelmaaf97/quijote>.

1. Preparación del corpus para modelado de secuencias

Un modelo de lenguaje predice palabra a palabra, así que el corpus debe prepararse pensando en secuencias.

- Cargue el texto de Don Quijote y segméntelo en oraciones (por ejemplo con el sentenizador de spaCy o NLTK); luego tokenice cada oración en palabras, conservando su orden y sin eliminar stopwords ni lematizar.
- Agregue tokens especiales de inicio <s> y fin </s> a cada oración.
- Divida las oraciones resultantes en conjuntos de entrenamiento (80%), validación (10%) y prueba (10%) de forma aleatoria.
- Reporte el tamaño del vocabulario del conjunto de entrenamiento y qué proporción de las palabras del conjunto de prueba no aparece en ese vocabulario.
- Explique con sus propias palabras qué relación tiene este problema de “palabras nunca vistas” con la dispersión de datos (data sparsity) discutida en clase.

2. Construcción de modelos n-grama (unigrama, bigrama, trigramas)

Implemente, desde cero (sin usar librerías especializadas en modelos de lenguaje como nltk.lm o kenlm), tres modelos de lenguaje basados en conteos:

- Unigrama: $P(w)$ estimado por frecuencia relativa en el corpus de entrenamiento.
- Bigrama: $P(w_n|w_{n-1})$ estimado como $\text{conteo}(w_{n-1}, w_n) / \text{conteo}(w_{n-1})$.
- Trigramas: $P(w_n|w_{n-2}, w_{n-1})$ estimado de forma análoga a bigrama.
- Use diccionarios o estructuras tipo defaultdict para almacenar los conteos de n-gramas.
- Calcule, para una oración de ejemplo del conjunto de validación, la probabilidad de la oración completa bajo cada uno de los tres modelos, aplicando la regla de la cadena (con su aproximación de Markov) vista en clase.

- Explique con sus propias palabras cómo el supuesto de Markov permite pasar de la regla de la cadena (exacta pero imposible de estimar) a los modelos n-grama (aproximados pero estimables).

3. Suavizado

Al evaluar oraciones del conjunto de validación o prueba es común encontrar n-gramas que nunca aparecieron en entrenamiento, lo que asigna probabilidad cero a toda la oración.

- Implemente suavizado de Laplace y, adicionalmente, suavizado add-k (con al menos dos valores de k) para el modelo de bigramas.
- Compare, con un ejemplo concreto, la probabilidad de una misma oración con y sin suavizado. ¿Qué problema práctico resuelve el suavizado?
- Explique con sus propias palabras por qué el suavizado “quita” probabilidad a los n-gramas frecuentes para dársela a los no vistos, y qué relación tiene esto con evitar la sobreconfianza del modelo.

4. Evaluación con perplejidad

- Calcule la perplejidad de los modelos de unigrama, bigrama y trigramas (todos con suavizado) sobre el conjunto de validación.
- Grafique o tabule la perplejidad de los tres modelos. ¿Cuál obtiene menor perplejidad? ¿Coincide con lo esperado según el trade-off de contexto vs. dispersión visto en clase?
- Seleccione el mejor modelo según validación y reporte su perplejidad final sobre el conjunto de prueba.
- Repita el cálculo de perplejidad del modelo de bigramas usando los distintos valores de k de suavizado de la sección 3. ¿Cómo cambia la perplejidad al aumentar k? ¿Por qué?

5. Aplicación práctica: autocompletado

- Usando el mejor modelo, según perplejidad, implemente una función simple de autocompletado: dado un fragmento de oración, devuelva las 5 palabras más probables como siguiente palabra.
- Pruebe la función con al menos 5 fragmentos distintos tomados de oraciones reales del conjunto de prueba y comente si las sugerencias son razonables.
- Como el corpus es una novela del siglo XVII, es normal que las sugerencias reflejen un vocabulario y estilo distintos al español actual; coméntelo si lo observa.

6. Análisis

- ¿Por qué la regla de la cadena de probabilidad, aunque exacta, no es utilizable directamente para estimar $P(\text{oración})$ con datos reales? Relacione su respuesta con los resultados de la sección 1 (vocabulario y OOV).
- Compare los resultados de perplejidad y de generación de texto entre unigrama, bigrama y trigramas. ¿Confirman el trade-off entre contexto y dispersión de datos visto en clase (n pequeño = fácil de estimar pero poco contexto; n grande = más contexto pero mayor dispersión)?
- ¿Qué efecto tuvo el suavizado sobre la perplejidad y sobre la calidad del texto generado? ¿Por qué es necesario incluso cuando el corpus de entrenamiento es grande?
- Si tuviera que elegir un valor de n para un sistema de autocompletado en producción, tomando en cuenta velocidad, memoria y calidad, ¿qué n elegiría y por qué?

Entregables

Entregable	Contenido
Link a repositorio	Repositorio (por ejemplo GitHub) con el código versionado del laboratorio.
Reporte escrito (máx. 4 páginas)	Resultados de las secciones 1 a 5 y respuestas al análisis (sección 6).