

Modelos de lenguaje


Probabilidad de secuencias y aproximaciones n-grama

Agenda de hoy

- 01 Probabilidad de secuencias
- 02 Aplicaciones: autocompletado, traducción, voz y LLMs
- 03 ¿Qué hace “bueno” a un modelo de lenguaje?
- 04 Regla de la cadena, a nivel intuitivo
- 05 Supuesto de Markov
- 06 Unigramas, bigramas y trigramas
- 07 Lecturas y cierre

Probabilidad de secuencias

Un modelo de lenguaje asigna una probabilidad a una secuencia de palabras: qué tan plausible es esa oración en el idioma. La misma idea sirve para predecir la palabra siguiente dado lo que ya se ha escrito.



Dos usos prácticos: puntuar qué tan probable es una oración completa, o predecir la palabra más probable dado el contexto anterior.

Aplicaciones de los modelos de lenguaje

Cualquier sistema que deba decidir qué palabra viene después, o qué tan natural suena una oración, se apoya en un modelo de lenguaje.

● Autocompletado

Predice la siguiente palabra mientras se escribe: buscadores, teclados de celular, editores de código.

● Traducción automática

Entre varias traducciones candidatas, el modelo de lenguaje ayuda a elegir la que suena más natural en el idioma destino.

● Reconocimiento de voz

Distingue entre secuencias que suenan parecido pero tienen distinta probabilidad como oración (el clásico “recognize speech” vs. “wreck a nice beach”).

● Modelos de lenguaje grandes (LLMs)

GPT y similares son, en esencia, modelos de lenguaje a gran escala entrenados para predecir el siguiente token.

¿Qué hace “bueno” a un modelo de lenguaje?

Un buen modelo de lenguaje asigna probabilidades más altas a las secuencias que un hablante real produciría, y probabilidades más bajas a las que no.

Secuencia probable

“el gato se subió a la mesa”

- Orden gramatical correcto
- Combinación de palabras común y con sentido
- $P(\text{“como cereal para desayunar”})$ es alta: es una combinación esperable

Secuencia improbable

“mesa la a subió se gato el”

- Orden alterado, agramatical
- Combinación de palabras poco frecuente
- $P(\text{“como zapatos para desayunar”})$ es baja: gramatical, pero implausible en el mundo

Regla de la cadena, a nivel intuitivo

La probabilidad de una oración completa se puede descomponer, sin ninguna aproximación, en el producto de la probabilidad de cada palabra dado todo lo que la precede.

El problema es práctico: para estimar $P(w_T \mid \text{historial larguísimo})$ casi ningún historial específico se repite en los datos de entrenamiento. Necesitamos una forma de simplificar ese historial — ahí entra el supuesto de Markov (siguiente slide).

Regla de la cadena

$$P(w_1, \dots, w_T) =$$

$$P(w_1) \cdot P(w_2 \mid w_1) \cdot P(w_3 \mid w_1, w_2) \cdot \dots \cdot P(w_T \mid w_1, \dots, w_{T-1})$$

cada factor: probabilidad de una palabra dado todo el historial previo

Exacta, pero no calculable directamente: la historia crece sin límite y los datos no.

Supuesto de Markov

Para hacer manejable la regla de la cadena, se asume que la probabilidad de la siguiente palabra depende solo de una ventana limitada de contexto reciente, no de toda la historia.

$$P(w_i | w_1, \dots, w_{i-1}) \approx P(w_i | w_{i-k}, \dots, w_{i-1})$$

Historial completo

- Usa todas las palabras anteriores, sin importar cuántas
- Exacto según la regla de la cadena
- Impráctico: casi ningún historial largo se repite en los datos

Ventana de Markov

- Usa solo las últimas k palabras como contexto
- Aproximación, no exacta
- Práctico: ese historial corto sí se repite y se puede estimar con datos reales

Unigramas, bigramas y trigramas como aproximaciones

Distintos valores de k en el supuesto de Markov dan lugar a distintos modelos n -grama.

Unigrama

$k = 0$

$$P(w_i)$$

Ignora el contexto por completo: cada palabra se trata como independiente.

Bigrama

$k = 1$

$$P(w_i | w_{i-1})$$

Depende solo de la palabra inmediatamente anterior.

Trigrama

$k = 2$

$$P(w_i | w_{i-2}, w_{i-1})$$

Depende de las dos palabras anteriores.

Probabilidad de la oración completa aproximada con bigramas: $P(w_1, \dots, w_n) \approx \prod_i P(w_i | w_{i-1})$

Más contexto, más dispersión: el trade-off de n

Aumentar n da más contexto, pero también hace que cada combinación específica de palabras aparezca cada vez menos veces en los datos de entrenamiento (data sparsity).

n pequeño (unigrama / bigrama)

- Fácil de estimar con pocos datos
- Poco contexto: oraciones menos coherentes

n grande (4-grama, 5-grama...)

- Más contexto y coherencia local
- La mayoría de secuencias específicas nunca aparece en el entrenamiento

En la práctica, trigramas / 4-gramas fue durante mucho tiempo el punto de equilibrio clásico, antes de que los modelos neuronales resolvieran la dispersión de otra forma.

Lecturas para preparar la clase

- **Jurafsky & Martin — N-gram Language Models**

Fundamento formal de los modelos n-grama: definición, suavizado y evaluación.

- **MIT OCW — Language modeling como base estadística**

Introducción a la probabilidad de secuencias desde la estadística.

- **NLTK Book — Generación simple de texto (opcional)**

Práctica ligera generando texto con modelos n-grama.

- **Jurafsky & Martin — capítulos de modelos de lenguaje**

Profundización adicional sobre el tema de la clase.

- **Hugging Face (ES), Cap. 1 — Modelos de lenguaje y tareas**

Panorama de tareas modernas de PLN construidas sobre modelos de lenguaje.

- **MIT 6.8610 — El lenguaje como eje de los modelos modernos**

Conexión entre estas ideas y los LLMs actuales.

Para recordar

- Un modelo de lenguaje asigna $P(\text{secuencia})$ usando la regla de la cadena de probabilidad.
- El supuesto de Markov limita el historial a una ventana de tamaño k para que sea estimable con datos reales.
- Unigramas, bigramas y trigramas son aproximaciones prácticas, cada una con distinto trade-off entre contexto y dispersión de datos.
- Estas ideas son la base estadística detrás del autocompletado, la traducción, el reconocimiento de voz y los LLMs actuales.