

Suavizado, vocabulario y evaluación

De modelos que asignan cero a modelos que se pueden medir

Agenda de hoy

- 01 Recordando la clase anterior: n-gramas
- 02 El problema de probabilidad cero
- 03 Add-one (Laplace) smoothing
- 04 Otras formas de suavizado
- 05 UNK y vocabulario cerrado / abierto
- 06 Evaluación de modelos: train / dev / test
- 07 Perplejidad y evaluación intrínseca
- 08 Límites de las métricas automáticas y cierre

Recordando: la aproximación n-grama

La clase anterior vimos que la regla de la cadena es exacta pero incalculable, y que el supuesto de Markov la vuelve manejable limitando el contexto a las últimas k palabras.

Estimación por conteos (máxima verosimilitud)

$$P(w_i | w_{i-1}) = C(w_{i-1}, w_i) / C(w_{i-1})$$

cuenta cuántas veces aparece el bigrama, dividido entre cuántas veces aparece el contexto

Esta estimación funciona bien para lo que ya se vio en el corpus de entrenamiento — pero, ¿qué pasa con lo que nunca se vio?

El problema de probabilidad cero

Ningún corpus de entrenamiento contiene todas las combinaciones posibles de palabras. Cuando un n-grama nunca aparece, su conteo es cero — y eso colapsa toda la oración.

Con conteos crudos (MLE)

$$C(\text{"probeta"}, \text{"azul"}) = 0$$

- El bigrama nunca apareció en el corpus de entrenamiento
- $P(\text{"azul"} \mid \text{"probeta"}) = 0$
- Aunque la oración sea perfectamente válida

Consecuencia práctica

$$P(\text{oración}) = 0$$

- La regla de la cadena multiplica todos los factores
- Un solo cero anula la probabilidad completa
- El modelo no puede distinguir “rara” de “imposible”

Add-one (Laplace) smoothing

La solución más simple: fingir que cada n-grama posible ya se vio una vez más de lo que realmente se vio. Es el primer ejemplo de suavizado y la base para entender los demás.

$$P_{\text{Laplace}}(w_i | w_{1:i-1}) = (C(w_{1:i-1}, w_i) + 1) / (C(w_{1:i-1}) + V)$$

V = tamaño del vocabulario (número de palabras distintas)

sumar 1 al numerador evita el cero; sumar V al denominador mantiene la distribución válida

Costo del remedio: le resta demasiada probabilidad a los n-gramas frecuentes y se la regala a los que nunca aparecieron — funciona como punto de partida, no como solución final.

Más allá de add-one: otras formas de suavizado

Add-one es un buen primer ejemplo, pero en la práctica se usan variantes que quitan menos probabilidad a lo observado.

Add-k

$k < 1$

Suma una fracción k en vez de 1, ajustable según el corpus.

Back-off

n -grama $\rightarrow (n-1)$ -grama

Si el n -grama no se vio, se retrocede a un contexto más corto.

Interpolación

combinación ponderada

Combina unigrama, bigrama y trigramas con pesos λ que suman 1.

Todas comparten la misma idea: quitarle un poco de probabilidad a lo visto para dársela a lo no visto, de forma más cuidadosa que add-one.

Palabras desconocidas: UNK y vocabulario

El suavizado ayuda con n-gramas no vistos entre palabras conocidas. Pero, ¿qué pasa cuando la palabra en sí nunca apareció en entrenamiento?

Vocabulario cerrado

closed vocabulary

- Se asume que todas las palabras posibles ya están en el vocabulario
- Útil cuando el dominio está muy controlado
- Poco realista para texto libre o abierto

Vocabulario abierto

token <UNK>

- Palabras fuera de vocabulario se reemplazan por un token especial <UNK>
- <UNK> se entrena como una palabra más, con sus propias probabilidades
- Es el enfoque estándar en modelos n-grama reales

Vocabulario fuera de dominio y subpalabras

El mismo problema aparece con corpus de dominios distintos: términos técnicos, nombres propios o jerga que el modelo nunca vio en entrenamiento son, en la práctica, palabras fuera de vocabulario (OOV).

Palabra completa

1 token = 1 palabra

Cualquier palabra no vista se pierde como <UNK>, sin importar si comparte raíz con palabras conocidas.

Subpalabras (BPE)

1 palabra = varios tokens

Divide en fragmentos frecuentes: “tokenizar” puede volverse “token” + “izar”.

Ventaja práctica


vocabulario cerrado real

Casi cualquier palabra se puede formar combinando subpalabras conocidas — casi no hay OOV.

Este es el enfoque que usan los tokenizadores modernos (Hugging Face, GPT, BERT): tokenización en subpalabras en vez de un vocabulario cerrado de palabras completas.

Evaluando modelos de lenguaje: los tres conjuntos

Antes de medir qué tan bueno es un modelo, hay que decidir con qué datos se entrena, se ajusta y se mide honestamente.



Regla de oro: el conjunto de test nunca debe influir en ninguna decisión de diseño del modelo — de lo contrario, la evaluación deja de ser honesta.

Perplejidad: midiendo qué tan bien predice el modelo

La perplejidad es la métrica intrínseca estándar para modelos de lenguaje: qué tan “sorprendido” está el modelo, en promedio, por el conjunto de test.

$$PP(W) = P(w_1, w_2, \dots, w_N)^{-1/N}$$

equivalente al inverso de la probabilidad geométrica promedio por palabra

menor perplejidad = el modelo asigna mayor probabilidad al texto real = mejor modelo

Se calcula sobre el conjunto de test, y solo tiene sentido comparar perplejidades calculadas con el mismo vocabulario y la misma tokenización.

Evaluación intrínseca, extrínseca y sus límites

La perplejidad es rápida de calcular, pero no es la única forma de evaluar un modelo — ni cuenta toda la historia.

Evaluación intrínseca

perplejidad

- Mide el modelo en sí mismo, sobre datos de test
- Rápida y barata de calcular
- No garantiza buen desempeño en una tarea real

Evaluación extrínseca

desempeño en tarea final

- Mide el impacto en la tarea real: traducción, dictado, autocompletado
- Más costosa y lenta de medir
- El estándar final para decidir si un modelo sirve

Límite clave: una menor perplejidad no siempre se traduce en mejores resultados para el usuario final — las métricas automáticas son una aproximación, no un sustituto del juicio humano.

Lecturas para preparar la clase

Jurafsky & Martin — Smoothing en modelos n-grama

Fundamento formal de add-one, add-k, back-off e interpolación.

Jurafsky & Martin — Evaluación de modelos de lenguaje

Train/dev/test, perplejidad y su relación con la entropía cruzada.

Hugging Face Tokenizers (ES) — Tokens desconocidos y subpalabras

Cómo la tokenización moderna evita el problema de vocabulario cerrado.

Hugging Face (ES), Cap. 1 — Modelos de lenguaje y tareas

Panorama de cómo estas ideas conectan con los modelos actuales.

Para recordar

- Los conteos crudos asignan probabilidad cero a lo que nunca se vio — el suavizado (add-one como primer ejemplo) reparte esa probabilidad.
- El vocabulario abierto y el token <UNK> resuelven las palabras desconocidas; las subpalabras reducen aún más el problema de OOV.
- Un modelo se evalúa dividiendo los datos en train / dev / test, y la perplejidad es la métrica intrínseca estándar — pero no reemplaza la evaluación extrínseca.