Natural Language Processing
Laboratorio #6
Etiquetado gramatical y reconocimiento de entidades nombradas

Instrucciones generales

- Individual.
- Entrega: Viernes 18 de septiembre, 2026. 23:59.
- Trabajar en un Jupyter Notebook.

Objetivo

Aplicar etiquetado gramatical (POS) y reconocimiento de entidades nombradas (NER) sobre las 3 novelas del dataset, y usar los resultados de las tres para sacar conclusiones comparativas sobre cómo la época de escritura y el estilo de cada autor se reflejan en el comportamiento del tagger y del modelo de NER: distribución de categorías gramaticales, riqueza de vocabulario, tipos y densidad de entidades, y tipos de errores del modelo frente a cada texto.

Dataset

Este laboratorio usa el dataset de Kaggle "Gutenberg Classic Novels Text Dataset", disponible en:

https://www.kaggle.com/datasets/jedidahwavinya/gutenberg-classic-novels-text-dataset

El dataset contiene el texto completo de 3 novelas clásicas de dominio público tomadas de Project Gutenberg. Como primer paso del laboratorio, identifique y reporte para cada una de las 3 novelas: título, autor(a), y año o época aproximada de publicación.

1. Preparación de la muestra de trabajo

El etiquetado gramatical y el reconocimiento de entidades se evalúan mejor sobre una muestra que se pueda inspeccionar a mano, así que este laboratorio trabaja sobre subconjuntos pequeños y representativos de cada una de las 3 novelas.

- Cargue el texto completo de las 3 novelas y aplique un pipeline similar de segmentación en oraciones y tokenización que construyó en el Laboratorio 5 a cada una por separado.
- De cada novela, seleccione una muestra aleatoria de al menos 100 oraciones para trabajar en detalle durante todo el laboratorio.
- Reporte, en una tabla comparativa con una fila por libro, cuántas oraciones y cuántos tokens totales tiene el libro completo, y cuántas oraciones y tokens componen la muestra de cada uno.

2. Etiquetado gramatical (POS tagging)

Use un tagger de POS preentrenado en inglés (por ejemplo spaCy con el modelo en_core_web_sm o en_core_web_md, o NLTK con nltk.pos_tag) para etiquetar cada token de la muestra de cada una de las 3 novelas.

- Asigne a cada token de cada muestra su categoría gramatical (POS) usando el tagger elegido.
- Reporte la distribución de categorías gramaticales (NOUN, VERB, ADJ, etc.) de cada libro por separado, y preséntelas juntas en una sola tabla o gráfico de barras agrupado para poder comparar los 3 libros a simple vista.
- Identifique al menos 3 palabras que reciban etiquetas distintas en oraciones distintas (ambigüedad de etiquetas), ya sea dentro del mismo libro o comparando su uso entre libros distintos. Para cada una, muestre el contexto y la etiqueta asignada en cada caso.
- Comente si alguna de esas asignaciones le parece incorrecta, considerando que cada novela pertenece a una época distinta (vocabulario, ortografía y construcciones de su tiempo) y que el tagger fue entrenado con inglés contemporáneo. ¿Hay algún libro donde el tagger cometa visiblemente más errores que en los otros? ¿A qué lo atribuye?

3. Tagsets y anotación

Elija uno de los 3 libros para el ejercicio de anotación manual de esta sección.

- Para 10 tokens de la muestra de ese libro, extraiga tanto la etiqueta universal (POS) como la etiqueta fina de Penn Treebank (tag_ en spaCy, o la salida directa de nltk.pos_tag).
- Explique con sus propias palabras, apoyándose en esos 10 ejemplos, qué información adicional aporta el tagset de Penn Treebank frente al tagset universal.
- Elija 5 oraciones de la muestra de ese libro y haga usted mismo, a mano y sin herramienta, el etiquetado gramatical palabra por palabra usando el tagset de Penn Treebank. Compare sus etiquetas con las del tagger automático y reporte en cuántos tokens coincidió.
- Comente los desacuerdos encontrados: ¿son errores del modelo, ambigüedad genuina, o simplemente diferencias de criterio del tagset?

4. Reconocimiento de entidades nombradas (NER)

Use un modelo de NER preentrenado en inglés (por ejemplo, el mismo modelo de spaCy usado en la sección 2) sobre un fragmento representativo de cada una de las 3 novelas (por ejemplo, los primeros 2-3 capítulos de cada una).

- Reporte, para cada libro por separado, cuántas entidades se detectaron en total y su distribución por tipo (PERSON, GPE, LOC, ORG, etc., según el esquema de su modelo). Preséntelo en una tabla comparativa de los 3 libros.
- Para cada libro, liste las 10 entidades de tipo PERSON y las 10 de tipo GPE/LOC más frecuentes. ¿Coinciden con los personajes y lugares principales que usted reconoce o esperaría de cada novela?
- Compare la densidad de entidades (entidades por cada 100 tokens) entre los 3 libros. ¿Alguno tiene notablemente más o menos nombres propios que los otros? ¿Tiene esto relación con el género o estilo narrativo del libro?

5. Esquema BIO

- Elija un fragmento de al menos 5 oraciones consecutivas de la muestra de uno de los 3 libros y construya manualmente la secuencia de etiquetas BIO token por token, a partir de las entidades detectadas por el modelo (corrigiéndolas si es necesario según lo observado en la sección 4).
- Presente el resultado como una tabla de dos filas, token y etiqueta BIO, igual que se mostró en clase.

6. Evaluación de entidades: anotación manual y métricas

Como las novelas no vienen con entidades anotadas, en esta sección usted construye su propio conjunto de referencia (gold standard) a mano para poder evaluar el modelo en cada libro.

- Para cada uno de los 3 libros, seleccione una muestra de al menos 20 oraciones (puede reutilizar las de la sección 1) y anote manualmente las entidades verdaderas: personajes, lugares y otras entidades relevantes, con su tipo y su span exacto.
- Compare las predicciones del modelo de NER contra su anotación manual y calcule precisión, recall y F1 de dos formas para cada libro: (a) a nivel de token y (b) a nivel de entidad completa. Puede apoyarse en scikit-learn (classification_report) o en la librería seqeval.
- Presente los 6 resultados (3 libros × 2 formas de evaluación) en una sola tabla comparativa.
- Compare los resultados entre sí: ¿la evaluación por token da una impresión más optimista que la evaluación por entidad completa en los 3 casos? ¿El modelo funciona notablemente mejor en algún libro que en otro?

7. Conclusiones comparativas: épocas y autores

- Con base en la distribución de categorías gramaticales (sección 2) y en la densidad y tipos de entidades (sección 4), ¿qué diferencias de estilo puede inferir entre los 3 autores? (por ejemplo, mayor o menor uso de adjetivos, más o menos diálogo, más o menos nombres propios).
- ¿Por qué la ambigüedad de etiquetas POS es, en el fondo, el mismo tipo de problema que enfrenta un modelo de lenguaje n-grama al decidir “qué palabra sigue” dado un contexto? Relacione su respuesta con la idea de que ambos son problemas de predicción condicionada al contexto.
- El tagger y el NER que usó fueron entrenados con inglés contemporáneo, pero las 3 novelas son de épocas distintas. ¿Qué tipo de errores atribuiría a esta diferencia de dominio en cada caso, y cómo se relaciona con el problema de vocabulario fuera de dominio (OOV) discutido en laboratorios anteriores?
- Retomando la comparación de la sección 6 entre evaluación por token y por entidad completa, si tuviera que reportar el desempeño de un sistema real de NER a un cliente, ¿cuál de las dos métricas usaría como número principal, y por qué?
- A modo de cierre, escriba un párrafo breve resumiendo qué le dicen, en conjunto, los resultados de las 3 novelas sobre la relación entre época/autor y el desempeño de herramientas de NLP entrenadas con datos contemporáneos.

Entregables

Entregable	Contenido
Link a repositorio	Repositorio (por ejemplo GitHub) con el código versionado del laboratorio.
Reporte escrito (máx. 6 páginas)	Identificación de los 3 libros (sección Dataset), resultados de las secciones 1 a 6 y conclusiones comparativas de la sección 7.